

· 毒理学专刊 ·

机器学习方法应用于化学物质毒性测试研究进展

冯驰原, 首莹清, 靳 远, 于典科

(青岛大学公共卫生学院, 山东 青岛 266071)

于典科, 教授, 博士生导师, 国家高层次海外青年人才计划和泰山学者青年专家, 兼任中国毒理学会生物化学与分子毒理专业委员会主任委员、中国环境诱变剂学会副秘书长、中国环境诱变剂学会生物标志物专业委员会主任委员和常务理事及中华预防医学会卫生毒理学会常务委员。研究方向为系统毒理学, 解析遗传和表遗传因素在环境毒物代谢及诱发肿瘤等复杂疾病中的调控机制, 应用系统生物学手段建立基于毒性通路的毒物毒作用模式和有害结局路径方法, 为新化学物质的毒性评价和风险评估提供新策略, 荣获中国毒理学替代法发展奖。现主持国家级科研项目 4 项, 发表研究论文 100 余篇, 其中第一/通信作者 SCI 论文 38 篇, 总引用 5455 次, H 指数 41。



摘要: 随着高通量技术的发展和海量毒理学数据的涌现, 毒理学研究步入大数据时代。如何高效整合现有的毒理学数据、阐明化学物质毒作用规律并利用规律提示新信息, 实现新化学物质毒性高效预测, 是毒理学研究的前沿问题之一。鉴于传统化学物质毒性测试方法高成本、低通量且难以揭示机制信息, 迫切需求高通量预测模型。机器学习方法已应用于毒性测试, 如监督学习模型、无监督学习模型、深度学习模型、强化学习模型和迁移学习模型, 其常用的化学物质特征数据主要包括化学物质结构数据、文本数据、毒理基因组数据和图像数据。将机器学习应用于毒性测试的研究潜力巨大, 且取得一定进展, 但目前研究主要集中于数据处理和模型开发, 尚未形成应用度广、共识性强的方法。此外, 机器学习模型的预测精度不仅取决于算法, 亦受到数据质量的影响, 算法与数据质量的相互促进发展亦是一大挑战。总之, 毒理学领域的数据处理和模型构建需要跨学科的合作和技术创新, 随毒理学数据库的日趋完善, 各种模型算法的不断优化, 基于机器学习模型开展新化学物质毒性预测将日益高效、准确, 对保障人类健康和环境安全起到重要作用。

关键词: 机器学习; 毒理学大数据; 毒性预测; 毒理学数据库

中图分类号: R99

文献标志码: A

文章编号: 1000-3002-(2024)10-0773-10

DOI: 10.3867/j.issn.1000-3002.2024.10.007

目前, 化学物质的毒性测试领域正经历巨大变革。传统的毒性测试主要依赖于动物试验^[1-3], 虽可较全面评估化学物质对生物机体的潜在危害, 但通量低、成本高, 难以提供机制信息, 且外推到人时具有较大不确定性^[4-5]。2007 年, 美国国家研究委员会 (National Research Council, NRC) 发布《21 世纪的毒性测试: 愿景与策略》指南, 提出未来毒性测试应基于 (体外) 毒性通路的扰动而非 (体内) 顶端终点效应, 对推动新型毒性测试框架的

建立具有里程碑意义^[6]。随着高通量组学技术和计算机技术的发展, 基于大数据的人工智能 (artificial intelligence, AI) 算法, 尤其是机器学习, 在新化学物质毒性预测的应用研究中正快速增加^[7-8]。机器学习能够处理和解析大型复杂数据集, 在处理多源性数据和数据不平衡问题上也显示出独特的优势^[9-10]。基于体外试验数据和化学物质特征的机器学习算法, 可高通量预测化学物质与机体的相互作用及潜在的毒效应, 筛选出确实需要进一步开展体外及体内毒性试验的优控化学物质, 减少对动物试验的依赖^[11-13], 成为构建化学物质新型毒性测试框架的重要工具。本综述深入剖析目前传统毒性测试方法所面临的低通量、高成本等问题, 指出其在应对不断增长的化学物质毒性评估需求上存在的效率瓶颈, 据此提出机器学习技术作为提升毒理学

基金项目: 国家自然科学基金 (82273671); 国家自然科学基金 (82241086)

作者简介: 冯驰原, 硕士研究生, 主要从事系统毒理学毒性测试新方法研究。

通信作者: 于典科, E-mail: dianke.yu@qdu.edu.cn

研究效能的关键途径。综述聚焦于适合机器学习算法的毒理学特征数据类型,系统梳理机器学习在毒性测试领域的应用进展及其所面临的挑战,为推进新型化学物质毒性预测方法的开发和保障人类健康与环境安全提供理论依据和技术支持。

1 毒性测试中常用的机器学习模型

机器学习是 AI 领域的重要分支。工作原理是利用计算机算法从大量已知的数据中学习,发现数据之间的关联性,利用关联性来预测未知数据。这些数据不局限于某一类型,既可基于化学物质的结构特征,如相对分子质量、分子式和氢键受体等,也可基于组学数据利用机制信息进行预测。早期的机器学习模型,如简单的线性回归和逻辑回归,对原始数据的质量要求比较高,虽然在处理小规模和低维数据上表现良好,但面对更复杂的数据结构和高维特征数据时效果并不明显^[14-15]。随时间推移,更为复杂的模型如支持向量机(support vector machines, SVM)、决策树(decision tree, DT)和随机森林(random forest, RF)逐渐崭露头角,提高了预测的准确性和模型的泛化能力^[16-18]。近 10 年来,

深度学习技术开始兴起^[19],借助于神经网络特别是深层神经网络的强大学习能力,机器学习模型能处理比以往更加复杂的数据类型,如图像、声音和文本数据等^[20-21],极大提升了机器学习模型的性能,也将模型应用推广到自动驾驶、医疗诊断和医药化工研发等领域。然而,单纯依赖模型的复杂度提升预测能力,也会引发过拟合、计算成本高以及模型的解释性差等问题。因此,未来的机器学习模型可能更多地关注模型的可解释性和泛化性(generalization),且该发展方向也与毒理学揭示毒作用“黑匣子”的研究愿景相一致,在毒理机制解析、毒性预测和风险评估等方面将具有广泛的应用前景。

1.1 监督学习(supervised learning)模型

监督学习模型主要依靠具有明确定义输出标签的数据集,训练算法模型预测或分类未见数据的能力,常见的算法包括线性回归、逻辑回归、DT、SVM 和 RF 等(图 1)。借助标注的毒理学数据集,监督学习模型能够对化学物质的毒性等级和类型进行预测。

1.1.1 线性回归

线性回归模型是一种用于建立变量之间线性关系的统计模型。它假设自变量(或称为解释变




图 1 几种机器学习模型的工作原理。

量)与因变量之间存在线性关系,通过最小化观察值与模型预测值之间的差异拟合最佳的线性函数。Henk 等^[22]运用该算法对 12 种有机磷酸酯的生物浓度、生物转化、乙酰胆碱酯酶抑制和急性水生毒性等多个生物学终点数据进行建模,对有机磷系化学物质进行毒性预测。

1.1.2 逻辑回归

逻辑回归主要用于处理毒性预测中的二元分类问题,通过逻辑函数将自变量的线性组合转化为 1 个 0~1 之间的概率值,表示样本隶属于特定类别的可能性。Jay 等^[23]利用该算法评估了来自多个地理区域的 2524 个配对的海水沉积物化学特征和毒性数据,预估了沉积物毒性的剂量-效应关系。

1.1.3 决策树

DT 是一种树形结构的算法,通过系列判断规则对数据进行分类或回归,具有可解释性强的优点。Gupta 等^[24]利用 DT 方法构建定量结构-活性关系(quantitative structure-activity relationships, QSAR)模型,预测挥发性有机化学物质的感官刺激毒性,识别出致毒效应的主要化学物质。

1.1.4 支持向量机

SVM 通过找到一个超平面,将不同类别的数据点有效区分,并实现边界间隔最大化,在处理高维度数据和非线性数据时表现出色。Zheng 等^[25]根据混合暴露污染物的特性数据(污染物名称、类型和来源等)为混合物样本编码,应用 SVM 算法学习数据的非线性结构和高阶相关性,依据致突变性对复杂混合物分类,并预测出高危险度的污染物成分。

1.1.5 随机森林

RF 是由多个 DT 构成的集成学习方法,每个决策树均基于数据随机子集进行训练,具有良好的准确性和鲁棒性(robustness),能够处理复杂的高通量数据,已被成功用于化学物质毒性预测、药物筛选和标志物识别等。Polishchuk 等^[26]基于 644 种化学物质的模型集构建 RF 模型,在 2 个分别包含 339 种和 110 种化学物质的测试集进行化学物质毒性预测,发现化学物质的亲脂性和极化性是影响其毒性的关键因素。

1.2 无监督学习(unsupervised learning)模型

无监督学习主要分析化学物质数据集的潜在结构,以发现化学物质新的类别或毒作用模式。

1.2.1 主成分分析

主成分分析主要通过降低数据维度发现新的数据模式,如通过线性变换将原始数据映射到新的坐标系,寻求数据在新坐标系下的方差最大化,在

毒理学中主要用于处理多组学数据。Boruvka 等^[27]在捷克北部和东北部的 14 个地点应用该算法成功区分地质富集和人为污染导致的多种重金属污染。

1.2.2 聚类算法

聚类算法的目的是将数据集样本区分为具有相似特征的组或簇。K-means 是常用的聚类算法,依据将样本分类至最临近的簇心,基于对生物学数据性质和结构的理解实现样本分类。Deng 等^[28]基于有害化学品事故数据库中的事故原因、过程和结果的文本描述频率,应用 K-means 聚类分析构建事故情景,建立有害化学品系统性风险评估和事故预防方法。

1.3 深度学习(deep learning)模型

基于卷积神经网络的深度学习,主要应用于图像、文本、语音等信息的分类与回归。神经网络模仿人脑的多层结构,由多个“神经元”互相链接,通过学习输入和输出信号之间的映射关系进行化学物质毒作用模式识别、毒性分类和预测。目前该模型的应用还存在一定局限性。首先,该模型存在表达能力的限制,其描述数据的复杂度有限。其次,该模型缺乏反馈机制,在图像识别、语音识别之外的其他领域的应用过程中存在有延迟反馈现象。在毒理学领域,该模型的应用正逐步增多。Basak 等^[29]使用拓扑结构、拓扑化学、几何和量子化学等指标作为层次化分子描述符,应用神经网络算法开发 69 种苯衍生物对大头鲢(*Aristichthys nobilis*)的急性水生毒性预测模型,发现多层次指标联用比单一的层次指标更适宜于模型构建和应用。

1.4 强化学习(reinforcement learning)模型

强化学习,又称再励学习、评价学习或增强学习。强化学习模型是以“试错”的方式进行学习,其与监督学习不同的地方主要表现于强化信号。强化学习中由环境提供的强化信号是对产生动作的好坏做一种评价(通常为标量信号),而不是告诉强化系统如何去产生正确的动作。强化学习的优势在于非常适用于复杂环境下的决策问题,特别是在面对大规模状态空间和动态变化的环境时,传统的监督学习和无监督学习方法往往面临困难。强化学习可通过与环境的交互学习优异策略,进行自主学习和逐步优化,从而解决复杂现实问题。James 等^[30]利用果蝇多巴胺神经元中输出神经元的反馈强化,预测发出强化预测错误的信号,制定可塑性规则,以最大限度地减少预测误差,验证输出神经元在模拟中学习准确的强化预测。

1.5 迁移学习(tranfer learning)模型

大多数机器学习模型在训练和测试阶段通常

采用一致的数据集,但在毒理学研究中很难实现对大量化学物质或样本的充分标记。迁移学习模型可将已有化学物质的知识迁移到新化学物质样本的识别任务中,从而在新任务中应用少量标记样本完成训练过程。Tung 等^[31]于 2019 年首次开发出迁移学习算法,通过采用基于树的集成多任务学习算法,将 3 个与皮肤致敏相关联的不良结局路径(adverse outcome pathway, AOP)中的关键事件(蛋白结合、角质细胞活化和树突状细胞活化)相结合,以预测人体皮肤致敏原。其中,人体皮肤致敏数据是主要学习任务,而 AOP 的 3 个关键事件则作为辅助任务促进知识迁移,其优势在于可同时处理多个任务,并能够发现、共享知识进行知识迁移,且可在模型内部实现组内的知识迁移。该方法不仅提升了预测的准确度和覆盖率,而且通过知识迁移显著增强了模型性能,为缺乏数据的新化学物质毒性预测提供了新策略。

2 机器学习模型常用的化学物质特征数据

本质上,机器学习模型均是通过使用各种算法从输入的化学物质特征数据中学习有效特征以实现毒性预测,因此化学物质特征数据的选择和处理对于构建机器学习模型至关重要^[32]。良好的化学物质特征数据集不仅能为模型构建提供充足决策信息,还有利于降低模型的复杂性以提高计算效

率。目前机器学习模型常用的化学物质特征数据主要包括化学物质结构数据、文本数据、毒理基因组数据和图像数据(图 2)。

2.1 化学结构数据

化学结构信息是研究化学物质毒性最本质的数据源。化学物质相关的结构信息可从 PubChem 和 ChEMBL 等化学物质数据库中获取,经转换成数字或二进制值的分子描述符或分子指纹后纳入模型。分子描述符的类别主要包括:① 结构性描述符:表述化学物质的基本构成信息,包括原子数量、键的种类和数量及相对分子质量等;② 拓扑描述符:表述分子的几何形状和大小描述符,如 Wiener 指数和连通性指数等;③ 几何描述符:反映分子空间构型的三维参数,如分子的表面积、体积和形态系数等;④ 量子化学描述符:表述化学物质分子电子结构的深入视角。分子指纹的类别主要包括:① 基于子结构密钥的指纹:使用哈希函数将有序的片段转换为 N 位字符串,代表存在或不存在预定的官能团、子结构或片段;② 圆形指纹:以每个非氢原子或片段为中心,迭代拓展到邻接结构,用于描述分子的结构和相似性;③ 拓扑指纹:基于原子和化学键类型的分子拓扑结构,用于描述分子的拓扑性质;④ 药效团指纹:用于药物研发和分子表征;⑤ 蛋白质-配体相互作用指纹;⑥ 基于形状的指纹;⑦ 强化指纹;⑧ 多指纹联合。除分子描述符和分子指纹外,深度学习也常用简化分子线性输入规范




图2 毒理学研究中机器学习常用化学物质特征数据及模型。

(simplified molecular input line entry system, SMILES)等进行表征, SMILES 符号由一连串不间断的字母组成, 采用纵向优先遍历树算法将化学结构进行转化。Liu 等^[33]采用递归特征消除(recursive feature elimination)方法结合 SVM 算法建立回归和分类模型, 使用二维分子描述符和分子指纹预测有机污染物的生物浓度因子和急性毒性分类。Zhang 等^[34]利用 7 种分子指纹和 3 种机器学习方法, 开发了 3 种新的集成分类模型预测化学物质的致癌性。Zang 等^[35]利用高通量筛选和化工流程数据, 基于机器学习构建可预测化学物质的分配系数、溶解性、沸点和熔点与生物浓缩因子等理化性质的定量结构-性质关系(quantitative structure-property relationship, QSPR)模型。

2.2 文本数据

毒理学文本数据主要来源于化学物质毒性报告、研究论文及毒理学数据库的文本描述等, 这些数据记录了化学物质的毒作用机制和毒效应等重要信息。结合机器学习算法, 文本数据在化学物质毒性预测、机制解析和标志物筛查方面发挥重要作用。例如, Varghese 等^[36]整理了约 7000 份砷毒性相关科学文献摘要, 应用机器学习算法及深度学习框架进行比对分析, 发现深度学习模型在自动文本分类中更具优越性。Minet 等^[37]通过自动文本挖掘等方法, 鉴定了分子、细胞和组织层面的关键事件, 构建了 1 个黏液分泌过多致慢性阻塞性肺疾病的 AOP, 系统阐述了该不良结局的分子机制。

2.3 毒理基因组数据

毒理基因组数据泛指毒物暴露条件下, 反映生物体内基因表达和(或)活性变化的组学数据, 为筛选毒物扰动的关键分子、揭示分子毒理机制提供海量信息。Rahman 等^[38]使用体外试验组学数据及 SVM 等机器学习模型, 鉴定了具有最小冗余的生物标志物, 用于预测毒效应终点。Chen 等^[39]利用深度生成对抗网络(generative adversarial network, GAN)开发出毒理基因组学数据生成模型, 利用 Open TG-GATEs 数据库的大鼠肝脏转录组数据, 可产生出与原始基因表达谱近乎一致的 Tox-GAN 转录谱。

2.4 图像数据

高分辨率的细胞和组织病理等图像数据为评价细胞形态变化、组织结构变动乃至毒效应终点提供了依据。随着机器学习技术的引入, 图像数据在毒物毒性评估、毒效预测及生物标志物识别的应用受到越来越多的重视。William 等^[40]提出了一种基

于多尺度卷积神经网络(multi-scale convolutional neural network, M-CNN)的算法, 基于概率输出的定量描述将细胞图像分类为不同表型。Atila 等^[41]整合 796 张经数据增强的单个彗星灰度图像, 应用 CNN 算法精准地对彗星图像进行分类。Puri 等^[42]基于自动机器学习(AutoML)模型对 1277 张肝组织病理图像进行分析, 准确识别出肝组织坏死的图像模式。上述研究展现了机器学习技术对图像数据在毒理学领域的应用和发展中的革命性贡献。

2.5 化学物质特征数据相关的数据库

目前已有多个表征上述毒理学特征数据的公开数据库, 为机器学习模型开发提供数据支撑。例如, PubChem 数据库归档了约 1.3 亿个有机小分子的生物活性、生物测定和蛋白基因靶标数据, 存储了约 1.1 亿个化学物质的化学结构、可溶性和熔点等理化性质信息; ChEMBL 数据库提供了 240 万多个化学物质的定性或定量测量数据, 以及基于 1.5 万多个生物学靶点获得的 2000 万个生物活性测定数据; CTD 等数据库基于已发表的毒理学研究, 整合了环境暴露、基因和表型改变乃至疾病的交互作用。Open TG-GATEs 数据库进行了单次和短期重复给药的大鼠试验, 并提供了基因表达谱、生化指标和组织病理图像。这些数据库促进了全球化的毒理学信息交互, 能直接服务于环境或药物与基因交互作用引起的损伤和疾病相关研究, 从而推动毒理学及相关领域的发展(表 1)。

3 机器学习在化学物质毒性测试中面临的挑战

与传统的数据统计和处理方法相比, 机器学习可解析数据库和组学数据等庞大的数据集, 基于现有的化学物质和毒性信息提取关键知识特征, 对化学物质进行分类、毒性预测和复合暴露分析等^[8, 43-44]。例如, Judson 等^[45]在 2008 年使用模拟的多尺度数据模型对化学品毒性进行分类, 减少了传统毒性测试大量时间和成本投入。然而, 机器学习技术的发展也受到一些挑战。首先, 高质量的毒理数据集对于精准有效的机器学习模型构建至关重要, 但早期毒理学数据获取的困难性、各实验室试验手段的异质性以及试验数据描述的差异性问题, 均可能影响毒理数据质量乃至模型的可靠性^[11, 46-47]。其次, 复杂的机器学习算法会呈现“黑箱”性质, 很难解释其内部的决策过程和预测行为的生物学逻辑, 机器学习模型的可解释性差是其在临床应用和医疗监

表 1 常见的毒理学数据库

名称	数据类型	数据库功能描述
PubChem	化学结构数据	来自高通量筛选和文献的约 1.3 亿个化学物质的理化性质、生物活性数据和蛋白靶标等,提供可分析生物测试结果的程序化工具
ChEMBL	化学结构数据	约 240 万个化学物的定性或定量测试数据;以及基于 1.5 万多个生物学靶点获得的 2000 万个生物活性测定数据
ToxCast	化学结构数据	2000 多种化学物质进行 700 多项人原代细胞、细胞系和大鼠原代肝细胞等体外细胞培养测试和线虫等全新的低等动物模型的高通量筛选后的生物数据
Tox 21	化学结构数据	约 1 万种化学物质在 75 项核受体和应激反应途径试验中的试验数据;通过高通量筛选技术评估化学物质的毒性和对生物体代谢、信号转导和基因表达等的影响
Integrated Chemical Environment (ICE)	化学结构数据	包含大鼠、人、兔和豚鼠的体内数据和来自靶向测试、非靶向测试的体外数据;提供数据管理、序列比对、结构比对和分子对接等分析工具和功能
Gene Expression Omnibus (CEO)	毒理基因组数据	收录全球研究者上传的微阵列芯片、二代测序及单细胞测序等高通量基因组数据;提供数据分析和可视化工具
Open TG-GATEs	毒理基因组数据和图像数据	170 种化学物质大鼠肝毒性、肾毒性的病理切片、血液生化指标、组织样本的微阵列基因表达,以及人和大鼠肝原代细胞的基因表达数据
DrugMatrix	毒理基因组数据	600 种化学物质大鼠原代肝细胞和 8 种大鼠组织毒性的微阵列基因表达数据;多剂量、多时间点暴露
LINCS L1000	毒理基因组数据	包含 12 328 个不同的基因和对应的数值矩阵,其中 978 个高通量测得,11 350 个计算所得;约 2 万多种小分子化学物质在体外 9 种人类细胞系中的基因表达数据,多时间,多剂量
Immunological Genome Project (ImmGen)	毒理基因组数据	小鼠中 250 种免疫细胞类型的全基因组转录表达谱
AOP-wiki	文本数据	收录 400 多个来自不同国家学者构建的 AOP;AOP 可视化网络串联起分子起始事件、关键事件、有害结局之间的关系
AOP4EUpest	文本数据	基于 AOP-wiki 数据库研究农药的分子起始事件、关键事件和不良结局;附带农药化学物注释信息
Gene Ontology	文本数据	包含分子功能、细胞组分、生物过程 3 个主要功能;提供基因功能注释、富集分析等工具
Molecular Signatures Database (MSigDB)	文本数据	包含来自 7 个不同分组模块的约 3.2 万个带注释的基因集;用于人类和小鼠的基因集富集分析
Kyoto Encyclopedia of Genes and Genomes (KEGG)	文本数据	包含多个子数据库,涉及基因组信息、生物途径、生化性质、疾病和基因序列;提供直观图形来介绍众多信号通路以及各类通路之间的关系
REACTOME	文本数据	人类生物学反应及信号通路的相关数据和信息;提供生物过程的分子细节,作为分子转化的有序网络
Wikipathways	文本数据	收录 20 多个物种的通路和 1000 个代谢产物的通路的生物学途径;包含通路最新的图解、描述、引用、成分基因和蛋白质列表等
Pathway Commons	文本数据	集成来自 9 个公共数据库的超过 5700 条生物途径和 200 万次分子相互作用数据
Comparative Toxicogenomics Database (CTD)	文本数据	包含化学物质、基因、功能表型和疾病之间相互作用数据;提供通路分析功能
Chemical Effects in Biological Systems (CEBS)	图像数据	包含 27 项大鼠和小鼠的毒理基因组学研究,4000 多个微阵列和 75 个 2D 凝胶图像,1500 多只动物的临床化学和组织病理学结果

AOP: 有害结局路径.

管应用受限的关键问题^[48-50]。第三,化学物质引发毒性效应的机制复杂多样,对训练和验证机器学习模型提出了巨大的挑战,这一问题的解决有待于机制毒理学证据的不断丰富。第四,数据的隐私和安全、伦理问题均亟待关注。本团队在毒性机制阐述与机器学习模型结合方面进行了探索,如通过整合 TG-GATE 数据库和 DrugMatirx 数据库等的组学数据,以及 FDA-LTKB 药物数据库中的肝损伤标签和 LiverTox 中的临床报告,基于 XGBoost-SHAP 机器学习模型和“熵值法”数学模型,提炼出 11 条共性通路,系统阐述药物性肝损伤毒性机制,并构建基于机制信息的肝损伤预测模型^[51],为解决机器学习的“黑箱”问题提供了新的思路。

4 结语

以机器学习为代表的 AI 技术在毒理学中的应用已取得显著进展,其在高质量数据获取、模型可解释性等方面的瓶颈问题也逐步得到解决。例如,目前国际毒理学联合会(International Union of Toxicology, <https://council.science/member/iutox-international-union-of-toxicology/>)鼓励不同研究机构之间进行数据共享,以提高数据可用性和质量、提升机器学习模型的训练效果和泛化能力。贝叶斯网络或因果关系算法等机器学习算法的进步,可显著提高模型的解释性和透明度。新的机器学习模型如生成模型在毒理学领域的应用更值得期待^[52]。生成模型可通过对大数据的学习,自主生成相关化学物质的结构信息和毒性数据,在填补现有化学物质毒性数据空白、预测新化学物质毒性方面具有重要意义。此外,机器学习模型的算法也需要不断优化。目前在预测化学物质毒性时,通常仅依赖化学物质结构数据或仅依赖其毒理基因组数据,如何将它们之间的深层次联系,是提高模型预测准确性的关键。总之,毒理学领域的数据处理和模型构建需要跨学科的合作和技术创新,随着毒理学数据库的日趋完善,各种模型算法的不断优化,基于机器学习模型开展新化学物质毒性预测将日益高效、准确,对保障人类健康和环境安全起到重要作用。

参考文献:

[1] Zwickl CM, Graham J, Jolly R, *et al.* Principles and procedures for assessment of acute toxicity incorpo-

rating *in silico* methods[J / OL]. *Comput Toxicol*, 2022, 24: 100237 (2022-07-14) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/36818760/>. DOI: 10.1016/j.comtox.2022.100237.

- [2] Krewski D, Acosta D Jr, Andersen M, *et al.* Toxicity testing in the 21st century: a vision and a strategy [J]. *J Toxicol Environ Health B Crit Rev*, 2010, 13(2/4): 51-138.
- [3] Reduan FH, Shaari RM, Sayuti NSA, *et al.* Acute and subacute dermal toxicity of ethanolic extract of *Melastoma malabathricum* leaves in Sprague-Dawley rats[J]. *Toxicol Res*, 2020, 36(3): 203-210.
- [4] Flecknell P. Replacement, reduction and refinement [J]. *ALTEX*, 2002, 19(2): 73-78.
- [5] Browne P, Paul Friedman K, Boekelheide K, *et al.* Adverse effects in traditional and alternative toxicity tests[J / OL]. *Regul Toxicol Pharmacol*, 2024, 148: 105579 (2024-02-01) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/38309424/>. DOI: 10.1016/j.yrtph.2024.105579.
- [6] National Research Council (U. S.), Committee on Toxicity Testing and Assessment of Environmental Agents. *Toxicity testing in the 21st century: a vision and a strategy* [M]. Washington, DC: National Academies Press, 2007: 20-50.
- [7] Judson R, Richard A, Dix DJ, *et al.* The toxicity data landscape for environmental chemicals[J]. *Environ Health Perspect*, 2009, 117(5): 685-695.
- [8] Wu XT, Zhou QX, Mu L, *et al.* Machine learning in the identification, prediction and exploration of environmental toxicology: challenges and perspectives [J / OL]. *J Hazard Mater*, 2022, 438: 129487 (2022-06-27) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/35816807/>. DOI: 10.1016/j.jhazmat.2022.129487.
- [9] Klambauer G, Unterthiner T, Mayr A, *et al.* Deep-Tox: toxicity prediction using deep learning[J / OL]. *Toxicol Lett*, 2017, 280(S1): S69 (2017-10-20) [2024-06-26]. <https://doi.org/10.1016/j.toxlet.2017.07.175>.
- [10] Camacho DM, Collins KM, Powers RK, *et al.* Next-generation machine learning for biological networks [J]. *Cell*, 2018, 173(7): 1581-1592.
- [11] Luechtefeld T, Rowlands C, Hartung T. Big-data and machine learning to revamp computational toxicology and its use in risk assessment[J]. *Toxicol Res*, 2018, 7(5): 732-744.
- [12] Raies AB, Bajic VB. *In silico* toxicology: computational methods for the prediction of chemical toxicity[J]. *Wiley Interdiscip Rev Comput Mol Sci*, 2016, 6(2):

- 147-172.
- [13] Zhang Q, Li J, Middleton A, *et al.* Bridging the data gap from *in vitro* toxicity testing to chemical safety assessment through computational modeling[J/OL]. *Front Public Health*, 2018, 6: 261 (2018-09-11) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/30255008/>. DOI: 10.3389/fpubh.2018.00261.
- [14] Ye YZ, Xiong Y, Zhou QJ, *et al.* Comparison of machine learning methods and conventional logistic regressions for predicting gestational diabetes using routine clinical data: a retrospective cohort study [J/OL]. *J Diabetes Res*, 2020, 2020: 4168340 (2020-06-12) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/32626780/>. DOI: 10.1155/2020/4168340.
- [15] Christodoulou E, Ma J, Collins GS, *et al.* A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models[J]. *J Clin Epidemiol*, 2019, 110: 12-22.
- [16] Han T, Jiang D, Zhao Q, *et al.* Comparison of random forest, artificial neural networks and support vector machine for intelligent diagnosis of rotating machinery[J]. *Trans Ins Measur Control*, 2018, 40 (8): 2681-2693.
- [17] Statnikov A, Wang L, Aliferis CF. A comprehensive comparison of random forests and support vector machines for microarray-based cancer classification [J/OL]. *BMC Bioinformatics*, 2008, 9: 319 (2008-07-22) [2024-06-26]. <https://doi.org/10.1186/1471-2105-9-319>.
- [18] Jin Y, Qi GS, Shou YQ, *et al.* High throughput data-based toxicity pathway-oriented development of a quantitative adverse outcome pathway network linking AHR activation to lung damages[J/OL]. *J Hazard Mater*, 2022, 425: 128041 (2022-05-05) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/34906874/>. DOI: 10.1016/j.jhazmat.2021.128041.
- [19] Goodfellow IJ, Courville A, Bengio Y. Scaling up spike-and-slab models for unsupervised feature learning[J]. *IEEE Trans Pattern Anal Mach Intell*, 2013, 35(8): 1902-1914.
- [20] Wang P, Fan E, Wang P. Comparative analysis of image classification algorithms based on traditional machine learning and deep learning[J]. *Pattern Recognit Lett*, 2021, 141: 61-67.
- [21] Lamontagne PJ, Benzinger TL, Morris JC, *et al.* OASIS-3: longitudinal neuroimaging, clinical, and cognitive dataset for normal aging and Alzheimer disease[J/OL]. *Medrxiv*, 2019 (2019-12-15) [2024-06-26]. <https://doi.org/10.1101/2019.12.13.19014902>.
- [22] Verhaar HJ, Eriksson L, Sjöström M, *et al.* Modeling the toxicity of organophosphates: a comparison of the multiple linear regression and PLS regression methods[J]. *Quantitat Struct-Activ Relatsh*, 1994, 13 (2): 133-143.
- [23] Field LJ, Macdonald DD, Norton SB, *et al.* Evaluating sediment chemistry and toxicity data using logistic regression modeling[J]. *Environ Toxicol Chem*, 1999, 18(6): 1311-1322.
- [24] Gupta S, Basant N, Singh KP. Estimating sensory irritation potency of volatile organic chemicals using QSARs based on decision tree methods for regulatory purpose[J]. *Ecotoxicology*, 2015, 24(4): 873-886.
- [25] Zheng WW, Tian DJ, Wang X, *et al.* Support vector machine: classifying and predicting mutagenicity of complex mixtures based on pollution profiles[J]. *Toxicology*, 2013, 313(2/3): 151-159.
- [26] Polishchuk PG, Muratov EN, Artemenko AG, *et al.* Application of random forest approach to QSAR prediction of aquatic toxicity[J]. *J Chem Inf Model*, 2009, 49(11): 2481-2488.
- [27] Borůvka L, Vacek O, Jehlička J. Principal component analysis as a tool to indicate the origin of potentially toxic elements in soils[J]. *Geoderma*, 2005, 128(3/4): 289-300.
- [28] Deng FJ, Gu WN, Zeng WW, *et al.* Hazardous chemical accident prevention based on K-Means clustering analysis of incident information[J]. *IEEE Access*, 2020, 8: 180171-180183.
- [29] Basak SC, Grunwald GD, Gute BD, *et al.* Use of statistical and neural net approaches in predicting toxicity of chemicals[J]. *J Chem Inf Comput Sci*, 2000, 40 (4): 885-890.
- [30] Bennett JEM, Philippides A, Nowotny T. Learning with reinforcement prediction errors in a model of the *Drosophila* mushroom body[J/OL]. *Nat Commun*, 2021, 12(1): 2569 (2021-05-07) [2024-06-26]. <https://doi.org/10.1038/s41467-021-22592-4>.
- [31] Tung CW, Lin YH, Wang SS. Transfer learning for predicting human skin sensitizers[J]. *Arch Toxicol*, 2019, 93(4): 931-940.
- [32] Jordan MI, Mitchell TM. Machine learning: trends, perspectives, and prospects[J]. *Science*, 2015, 349 (6245): 255-260.
- [33] Ai HX, Wu XW, Zhang L, *et al.* QSAR modelling study of the bioconcentration factor and toxicity of organic compounds to aquatic organisms using machine learning and ensemble methods[J]. *Ecotoxicol Environ Saf*, 2019, 179: 71-78.
- [34] Zhang L, Ai HX, Chen W, *et al.* CarcinoPred-EL:

- novel models for predicting the carcinogenicity of chemicals using molecular fingerprints and ensemble learning methods[J/OL]. *Sci Rep*, 2017, 7(1): 2118 (2017-05-17) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/28522849/>. DOI: 10.1038/s41598-017-02365-0.
- [35] Zang QD, Mansouri K, Williams AJ, *et al.* *In silico* prediction of physicochemical properties of environmental chemicals using molecular fingerprints and machine learning[J]. *J Chem Inf Model*, 2017, 57(1): 36-49.
- [36] Varghese A, Agyeman-Badu G, Cawley M. Deep learning in automated text classification: a case study using toxicological abstracts[J]. *Environment Systems and Decisions*, 2020, 40(4): 465-479.
- [37] Minet E, Haswell LE, Corke S, *et al.* Application of text mining to develop AOP-based mucus hypersecretion genesets and confirmation with *in vitro* and clinical samples[J/OL]. *Sci Rep*, 2021, 11(1): 6091 (2021-03-17) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/33731770/>. DOI: 10.1038/s41598-021-85345-9.
- [38] Rahman SM, Lan J, Kaeli D, *et al.* Machine learning-based biomarkers identification from toxicogenomics-bridging to regulatory relevant phenotypic endpoints[J/OL]. *J Hazard Mater*, 2022, 423(Pt B): 127141 (2021-09-11) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/34560480/>. DOI: 10.1016/j.jhazmat.2021.127141.
- [39] Chen X, Roberts R, Tong WD, *et al.* Tox-GAN: an artificial intelligence approach alternative to animal studies—a case study with toxicogenomics[J]. *Toxicol Sci*, 2022, 186(2): 242-259.
- [40] Godinez WJ, Hossain I, Lazic SE, *et al.* A multi-scale convolutional neural network for phenotyping high-content cellular images[J]. *Bioinformatics*, 2017, 33(13): 2010-2019.
- [41] Atila Ü, Baydilli YY, Sehirli E, *et al.* Classification of DNA damages on segmented comet assay images using convolutional neural network[J/OL]. *Comput Methods Programs Biomed*, 2020, 186: 105192 (2019-11-06) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/31733518/>. DOI: 10.1016/j.cmpb.2019.105192.
- [42] Puri M. Automated machine learning diagnostic support system as a computational biomarker for detecting drug-induced liver injury patterns in whole slide liver pathology images[J]. *Assay Drug Dev Technol*, 2020, 18(1): 1-10.
- [43] Baskin II. Machine learning methods in computational toxicology[J]. *Methods Mol Biol*, 2018, 1800: 119-139.
- [44] Sharma A, Lee BS. Toxicity test profile for deep eutectic solvents: a detailed review and future prospects[J/OL]. *Chemosphere*, 2024, 350: 141097 (2024-01-01) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/38171392/>. DOI: 10.1016/j.chemosphere.2023.141097.
- [45] Judson R, Elloumi F, Setzer RW, *et al.* A comparison of machine learning algorithms for chemical toxicity classification using a simulated multi-scale data model[J/OL]. *BMC Bioinformatics*, 2008, 9: 241 (2008-05-19) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/18489778/>. DOI: 10.1186/1471-2105-9-241.
- [46] Martini C, Liu YF, Gong H, *et al.* CEBS update: curated toxicology database with enhanced tools for data integration[J/OL]. *Nucleic Acids Res*, 2022, 50(D1): D1156-D1163 (2022-01-07) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/34751388/>. DOI: 10.1093/nar/gkab981.
- [47] De P, Kar S, Ambure P, *et al.* Prediction reliability of QSAR models: an overview of various validation tools[J]. *Arch Toxicol*, 2022, 96(5): 1279-1295.
- [48] Jia XL, Wang T, Zhu H. Advancing computational toxicology by interpretable machine learning[J]. *Environ Sci Technol*, 2023, 57(46): 17690-17706.
- [49] Jaganathan K, Tayara H, Chong KT. An explainable supervised machine learning model for predicting respiratory toxicity of chemicals using optimal molecular descriptors[J/OL]. *Pharmaceutics*, 2022, 14(4): 832 (2022-05-11) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/35456666/>. DOI: 10.3390/pharmaceutics14040832.
- [50] Azodi CB, Tang JL, Shiu SH. Opening the black box: interpretable machine learning for geneticists [J]. *Trends Genet*, 2020, 36(6): 442-455.
- [51] Jin Y, Shou YQ, Lei QK, *et al.* An entropy weight method to integrate big omics and mechanistically evaluate DILI[J]. *Hepatology*, 2024, 79(6): 1264-1278.
- [52] Chen X, Roberts R, Liu ZC, *et al.* A generative adversarial network model alternative to animal studies for clinical pathology assessment[J/OL]. *Nat Commun*, 2023, 14(1): 7141 (2023-11-06) [2024-06-26]. <https://pubmed.ncbi.nlm.nih.gov/37932302/>. DOI: 10.1038/s41467-023-42933-9.

Research progress in applications of machine learning in toxicity prediction

FENG Chiyuan, SHOU Yingqing, JIN Yuan, YU Dianke

(School of Public Health, Qingdao University, Qingdao 266071, China)

Abstract: With the emergence of high-throughput technology and massive toxicology data, toxicology research has entered the era of big data. How to efficiently integrate existing toxicological data, clarify the toxic effects of chemicals, and use these patterns to provide new information, in order to achieve efficient prediction of the toxicity of new chemical substances, is one of the cutting-edge issues in toxicology. In view of the high cost, low throughput and difficulty in revealing the mechanism information of traditional chemical toxicity testing methods, high throughput prediction models are urgently needed. Machine learning methods have been applied to toxicity testing, such as supervised learning models, unsupervised learning models, deep learning models, reinforcement learning models, and transfer learning models. Chemical characteristic data commonly used in machine learning models include chemical structure data, text data, toxicological genome data and image data. There is huge potential for applying machine learning to toxicity testing and machine learning methods have made some progress. However, current research focuses on the processing of data and development of models, which has failed to produce a widely used and accepted method. In addition, the prediction accuracy of machine learning models is not only dependent on algorithms, but also affected by data quality, and the mutual promotion and development of algorithms and data quality remains a big challenge. In short, data processing and model construction in the field of toxicology require interdisciplinary cooperation and technological innovation. With the increasing perfection of toxicology databases and the continuous optimization of various model algorithms, the toxicity prediction of new chemicals based on machine learning models will become increasingly efficient and accurate, playing an important role in ensuring human health and environmental safety.

Key words: machine learning; toxicological big data; toxicity prediction; toxicology database

Foundation item: National Natural Science Foundation of China (82273671); and National Natural Science Foundation of China (82241086)

Corresponding author: YU Dianke, E-mail: dianke.yu@qdu.edu.cn

(收稿日期: 2024-06-26 接受日期: 2024-10-08)

(本文编辑: 齐春会)